

Pirinç Yaprığı Hastalıklarının Derin Öğrenmeyle Sınıflandırılması

Ahmet Enes Yensiz
Bilgisayar Mühendisliği Bölümü
Bursa Teknik Üniversitesi
ahmetenesyensiz@gmail.com

Kemal Kerem Acar
Bilgisayar Mühendisliği Bölümü
Bursa Teknik Üniversitesi
kerem.acar1933@gmail.com

Özet - Bu çalışmada, dört farklı önceden eğitilmiş derin evrişimli sinir ağı (CNN) modeli olan Xception, VGG16, MobileNet ve ResNet50 kullanılarak pirinç yaprağı hastalıklarının sınıflandırılması amaçlanmıştır. 5932 etiketlenmiş görselden oluşan ve dört farklı hastalık sınıfı içeren dengeli bir veri kümesi kullanılmıştır (Bakteriyel Yanıklık, Blast, Kahverengi Leke ve Tungro). Veri kümesi %80 eğitim ve %20 test olarak, sınıflar eşit şekilde dağılacak biçimde ayrılmıştır. Model genellemesini artırmak amacıyla transfer öğrenme ve veri artırma teknikleri uygulanmıştır. Her bir model; doğruluk, kesinlik (precision), duyarlılık (recall), F1 skoru ve eğitim süresi gibi ölçütlerle değerlendirilmiştir. MobileNet modeli performans ve verimlilik dengesi açısından öne çıkarken, en yüksek sınıflandırma başarımına ResNet50 modeli ulaşmıştır. Elde edilen sonuçlar, derin CNN mimarilerinin pirinç hastalıklarının otomatik tespiti konusunda oldukça etkili olduğunu ve tarımsal izleme sistemlerine entegre edilebileceğini göstermektedir.

Anahtar Kelimeler - Pirinç yaprağı hastalığı, derin öğrenme, evrişimli sinir ağları, transfer öğrenme, görüntü sınıflandırma

I. GİRİŞ

Günümüzde dünya nüfusunun büyük bir kısmının temel besin kaynağı olan pirinç, tarımsal üretimde stratejik öneme sahip bir üründür. Ancak pirinç üretiminde karşılaşılan yaprak hastalıkları, bitki gelişimini olumsuz etkileyerek verimde ciddi düşüslere neden olabilmektedir. Özellikle Bakteriyel Yanıklık, Blast, Kahverengi Leke ve Tungro hastalıkları, pirinç yapraklarında kolayca gözlemlenebilir belirtiler göstermekte ve hızlı yayılım potansiyeline sahip olduğu için erken teşhis gerektirmektedir [1].

Bu tür hastalıkların tespitinde geleneksel yöntemler genellikle görsel incelemeye dayalıdır ve uzmanlık

gerektirir. Ancak bu yöntemler zaman alıcı, maliyetli ve subjektif değerlendirmelere açık olması nedeniyle pratikte yetersiz kalmaktadır [2]. Bu noktada yapay zekâ ve derin öğrenme gibi teknolojiler devreye girerek tarımsal hastalık teşhisi süreçlerini otomatikleştirme ve doğruluk oranlarını artırma potansiyeli sunmaktadır.

Bu çalışma kapsamında, pirinç yaprağı hastalıklarının sınıflandırılmasına yönelik bir görüntü işleme sistemi geliştirilmiştir. Toplam 5932 görüntüden oluşan ve dört farklı hastalık sınıfını içeren bir veri kümesi kullanılmıştır. Görüntüler, eğitim (%80) ve test (%20) olmak üzere rastgele ve dengeli bir şekilde bölünmüştür. Model eğitimi sürecinde veri artırma ve normalizasyon gibi ön işleme adımları uygulanmış, ardından transfer öğrenme yöntemiyle dört farklı önceden eğitilmiş CNN mimarisi (Xception, VGG16, MobileNet ve ResNet50) kullanılmıştır [3].

Her bir model, doğruluk, kesinlik, duyarlılık, F1 skoru ve eğitim süresi kriterlerine göre değerlendirilmiştir. Elde edilen sonuçlara göre ResNet50 modeli en yüksek sınıflandırma başarımını göstermiştir; MobileNet modeli ise düşük eğitim süresiyle öne çıkmıştır. Geliştirilen bu sistemin, tarımsal üretimde erken hastalık tespiti için etkili bir karar destek mekanizması oluşturabileceği düşünülmektedir.

II. LİTERATÜR ÖZETİ


Derin öğrenme tekniklerinin görüntü sınıflandırma problemlerinde sağladığı başarı, son yıllarda tarımsal uygulamalarda da yaygın şekilde kullanılmasına neden olmuştur. Özellikle Evrişimli Sinir Ağları (CNN), bitki yapraklarında görülen hastalık belirtilerini tespit etme konusunda etkili bir araç haline gelmiştir. Bitki hastalıklarının sınıflandırılmasına yönelik yapılan çalışmalar, transfer öğrenme ve önceden eğitilmiş modellerin kullanılmasının sınırlı veri kümeleri üzerinde dahi yüksek doğruluk oranları sağlayabildiğini ortaya koymaktadır [1].

Pirinç yaprağı hastalıklarının sınıflandırılması konusunda yapılan çalışmalarda genellikle VGG, MobileNet, ResNet ve Xception gibi popüler CNN mimarileri tercih edilmektedir. VGG mimarileri, derin ve katmanlı yapısıyla detaylı özellik çıkarımında başarılı olurken; MobileNet gibi daha hafif yapılı modeller, daha az kaynak kullanarak hızlı ve yeterli doğrulukta sonuçlar elde etmeye olanak sağlamaktadır [2]. ResNet ise artık haritaları öğrenmede derinlik sorununu residual bağlantılarla aşarak yüksek doğruluk değerlerine ulaşabilmektedir.

Bu alanda yapılan çeşitli akademik çalışmalarda, pirinç hastalıkları gibi çok sınıflı görüntü sınıflandırma problemlerinde transfer öğrenmenin, modelin daha az epoch süresinde daha iyi genelleme başarımı göstermesini sağladığı bildirilmiştir. Ayrıca veri artırma (data augmentation) yöntemlerinin, sınıf çeşitliliğini artırarak modelin aşırı öğrenmesini (overfitting) engellediği de belirtilmektedir [3].

Bu çalışmada, literatürde yaygın olarak kullanılan bu modellerin her biri bir araya getirilerek aynı veri kümesi üzerinde test edilmiş ve başarımları çok boyutlu ölçütlerle karşılaştırılmıştır. Böylece, hem ağır hem de hafif CNN mimarilerinin tarımsal uygulamalardaki performansları ortaya konmuştur.

III. MATERYAL VE YÖNTEM



[Şekil 3]: Veri setindeki pirinç yaprağı hastalıkları ve sağlıklı yaprağın sınıfları

A. Veri Kümesi

Bu çalışmada kullanılan veri kümesi, dört farklı pirinç yaprağı hastalığını içeren ve toplamda 5932 görselden oluşan bir görüntü sınıflandırma veri kümesidir. Görseller 224x224 çözünürlüğe sahip RGB formatında

olup her biri etiketlenmiş şekilde dört sınıfa ayrılmıştır: Bacterial Blight, Blast, Brown Spot ve Tungro. Her bir sınıf yaklaşık olarak eşit sayıda görüntü içerecek biçimde düzenlenmiştir.

Veri kümesi eğitim ve test olmak üzere ikiye ayrılmıştır. Eğitim kümesi %80, test kümesi ise %20 oranında tutulmuştur. Sınıflar dengeli bir şekilde dağılmış ve rastgele seçilerek bölünmüştür [1]. Görsel bazlı sınıflandırma yapılacağı için sınıflar arası örnek dağılım dengesi, modelin performansını doğrudan etkileyen bir faktör olarak değerlendirilmiştir.

B. Veri Ön İşleme

Görseller model eğitimi öncesinde çeşitli ön işleme adımlarına tabi tutulmuştur. İlk olarak tüm görsellerin boyutu 224x224 piksele yeniden ölçeklendirilmiş ve ardından piksel değerleri [0, 1] aralığına normalize edilmiştir.

Modelin genelleme performansını artırmak amacıyla 'ImageDataGenerator' sınıfı kullanılarak veri artırma (data augmentation) işlemleri uygulanmıştır. Bu işlemler arasında yatay çevirme, döndürme, yakınlaştırma ve kaydırma gibi rastlantısal işlemler yer almaktadır. Böylece eğitim verisindeki varyasyon artırılmış ve modelin farklı örneklerle karşı daha dayanıklı hale gelmesi sağlanmıştır.

C. Kullanılan Modeller

Bu projede transfer öğrenme yöntemi kullanılarak dört farklı önceden eğitilmiş CNN modeli uygulanmıştır: Xception, VGG16, MobileNet ve ResNet50. Bu modellerin tümü Keras kütüphanesinden alınmış ve ImageNet üzerinde önceden eğitilmiş ağırlıklara sahiptir.

Her modelin üst katmanları çıkarılmış ve yerine Flatten, Dense ve Dropout gibi katmanlar eklenerek dört sınıflı özel bir çıktı katmanı tanımlanmıştır. Bu şekilde modelin, sadece özellik çıkarımı aşamasında önceden eğitilmiş ağırlıkları kullanması, sınıflandırma kısmında ise projenin veri kümesine özgü öğrenme gerçekleştirilmesi sağlanmıştır.

D. Eğitim Süreci

Model eğitimi sırasında 'categorical_crossentropy' kayıp fonksiyonu ve 'Adam' optimizasyon algoritması kullanılmıştır. Öğrenme oranı varsayılan değer olan 0.001 ile başlatılmıştır. Eğitim sürecinde

`EarlyStopping` ve `ModelCheckpoint` callback'leriyle aşırı öğrenme (overfitting) riski azaltılmış ve en iyi ağırlıklar kayıt altına alınmıştır.

Her model için eğitim süreci maksimum 30 epoch boyunca sürdürülmüş, her bir epoch sonrası doğrulama kümesi üzerinde ölçümler yapılmıştır. Eğitim sırasında her bir modelin eğitim süresi ölçülmüş ve karşılaştırmalı analizlerde kullanılmıştır. Aşağıda dört modelin ortalama eğitim süreleri verilmiştir:

- **Xception**: ~84 dakika
- **VGG16**: ~177 dakika
- **MobileNet**: ~27 dakika
- **ResNet50**: ~78 dakika


IV. SONUÇLAR ve DEĞERLENDİRME

A. Doğruluk ve Kayıp Değerlerinin Analizi


Her bir modelin eğitim sürecinde doğruluk (accuracy) ve kayıp (loss) değerleri ayrı ayrı takip edilmiştir. Eğitim ve doğrulama verileri üzerindeki performans, epoch bazlı olarak kaydedilmiş ve grafikler ile görselleştirilmiştir.

Xception modeli, eğitim sürecinin 30. epoch'unda %98.0'in üzerinde doğruluk değerine ulaşmış; benzer şekilde MobileNet modeli %99.7 doğruluk ile en hızlı öğrenen model olmuştur. VGG16 ve ResNet50 modelleri ise daha uzun sürede öğrenme gerçekleştirmiştir.

Her model için doğruluk ve kayıp eğrileri aşağıda gösterilmiştir.



[Şekil 2]: Tüm modellerin eğitim ve doğrulama doğruluk grafiği



[Şekil 3]: Tüm modellerin eğitim ve doğrulama kayıp grafiği

B. Başarı Ölçütlerinin Karşılaştırılması

Her bir model; doğruluk, kesinlik (precision), duyarlılık (recall) ve F1 skoru açısından test verisi üzerinde değerlendirilmiştir. Bu ölçütlerin karşılaştırmalı olarak yer aldığı tablo aşağıda verilmiştir.


Model	Accuracy	Precision	Recall	F1 Score
Xception	0.98	0.98	0.98	0.98
VGG16	0.87	0.87	0.87	0.87
MobileNet	0.99	0.99	0.99	0.99
ResNet50	0.82	0.84	0.82	0.83

[Tablo 1]: Modellerin test verisindeki karşılaştırmalı başarı değerleri


C. Confusion Matrix İncelemesi

Modellerin tahmin başarımını daha detaylı analiz edebilmek için test verisi üzerinden confusion matrix'leri çıkarılmıştır. Özellikle MobileNet ve ResNet50 modelleri, dört sınıfta da dengeli ve doğru sınıflandırma yaparak minimal hata ile sonuçlanmıştır.


Xception modelinde ise "Blast" sınıfı ile "Brown Spot" sınıfı zaman zaman karıştırılmıştır. Bu da bu iki hastalığın görsel benzerliğinden kaynaklanmaktadır.




[Şekil 4]: Xception için confusion matrix



[Şekil 7]: ResNet50 için confusion matrix



[Şekil 5]: VGG16 için confusion matrix



[Şekil 6]: MobileNet için confusion matrix

D. Eğitim Süresi ve Kaynak Kullanımı

Modellerin eğitim süresi, eğitim verisinin boyutu ve mimarının karmaşıklığına bağlı olarak değişiklik göstermektedir. MobileNet modeli, çok daha kısa sürede eğitilerek en verimli model olmuştur. VGG16 ise daha uzun sürede eğitilmiş ancak doğruluk oranı görece düşük kalmıştır.

Aşağıdaki tabloda her bir modelin yaklaşık eğitim süresi dakikalar cinsinden verilmiştir.

Model	Ort. Eğitim Süresi(dak.)
Xception	~84
VGG16	~177
MobileNet	~27
ResNet50	~78

V. SONUÇ ve GELECEK ÇALIŞMALAR

Bu çalışmada, pirinç yaprağı hastalıklarının görüntü verisi üzerinden sınıflandırılması amacıyla dört farklı önceden eğitilmiş CNN modeli (Xception, VGG16, MobileNet ve ResNet50) kullanılmıştır. Model mimarileri transfer öğrenme yöntemiyle özelleştirilmiş, eğitim süreçlerinde veri artırma teknikleri uygulanmış ve her bir model doğruluk, kesinlik, duyarlılık, F1 skoru ve eğitim süresi açısından değerlendirilmiştir.

Elde edilen sonuçlara göre, MobileNet modeli %99'luk sınıflandırma doğruluğu ve kısa eğitim süresi ile en dengeli performansı sergilemiştir. ResNet50 modeli ise

yüksek başarı oranı ile dikkat çekmiş ancak daha uzun sürede eğitilmiştir. VGG16 ve Xception modelleri ise orta düzeyde sonuçlar üretmiş, özellikle VGG16'nin daha yüksek eğitim süresine rağmen doğruluk oranının görece düşük kaldığı gözlemlenmiştir.

Proje github linki : [Github](#)

Bu bulgular, farklı CNN mimarilerinin tarımsal hastalık sınıflandırma görevlerinde nasıl performans gösterdiğini karşılaştırmalı olarak ortaya koymaktadır. Ayrıca, veri artırma ve transfer öğrenme gibi yöntemlerin sınırlı veri kümeleriyle yapılan eğitimlerde önemli avantajlar sağladığı doğrulanmıştır.

Gelecek çalışmalar kapsamında, geliştirilen modelin mobil uygulamalara veya gömülü sistemlere entegre edilerek sahada gerçek zamanlı kullanımına yönelik optimizasyonlar yapılması planlanmaktadır. Ayrıca, sınıf sayısının artırılması, yeni hastalık türlerinin eklenmesi ve farklı bitki türlerine genellenebilirlik analizi de çalışmanın kapsamı genişletilerek ele alınabilir.

KAYNAKLAR

- [1] N. Sankalana, "Rice Leaf Disease Image Dataset," Kaggle, 2023. [Çevrimiçi]. Erişim: <https://www.kaggle.com/datasets/nimalsankalana/rice-leaf-disease-image>
- [2] N. Thai-Nghe, N. T. Tri ve N. H. Hoa, "Deep Learning for Rice Leaf Disease Detection in Smart Agriculture," in Artificial Intelligence in Data and Big Data Processing, Springer, 2022, ss. 659–670.
- [3] A. Yensiz ve K. K. Acar, "Rice Leaf Disease Classification using Transfer Learning," rice_leaf_classifier.ipynb, 2025. [Yerel çalışma].
- [4] A. Kaur, V. Kukreja, P. Tiwari, M. Manwal ve R. Sharma, "An Efficient Deep Learning-based VGG19 Approach for Rice Leaf Disease Classification," in Proc. IEEE I2CT, 2024, ss. 1–6.
- [5] S. Hassan, A. K. Maji, M. Jasinski ve E. Jasinska, "Identification of Plant-Leaf Diseases Using CNN and Transfer-Learning Approach," Electronics, c. 10, no. 12, s. 1388, 2021.
- [6] S. Sharma ve K. Guleria, "Pre-trained Deep Neural Network Based Features for Plant Disease Detection," Agriculture, c. 13, no. 5, s. 936, 2023.